

ПРАКТИЧЕСКАЯ РАБОТА №2. «ИССЛЕДОВАНИЕ ДАННЫХ НА PYTHON. ОБРАБОТКА ВЫБРОСОВ. ВИЗУАЛЬНЫЙ EDA»

Выброс — это точка данных, которая значительно отклоняется от остальных данных. Она может быть как намного выше, так и намного ниже остальных точек данных, и её наличие может существенно повлиять на результаты алгоритмов ML.

Как в набор данных появляются выбросы?

Существует несколько причин появления выбросов в наборе данных:

1) Ошибки ввода данных: Человеческий фактор, например, ошибки, возникающие во время сбора, записи или ввода данных, может привести к появлению выбросов в данных.

2) Ошибки измерительного прибора: Это наиболее распространенная ошибка, вызванная неисправностью используемого измерительного прибора.

3) Естественные выбросы: Если выброс не является искусственным, то это естественный выброс. Большая часть реальных данных относится к этой категории.

Анализ выбросов называется **анализом выбросов** (или **поиском выбросов**).

Типы выбросов: существует два основных типа выбросов.

Глобальные выбросы: **Глобальные выбросы** — это изолированные точки данных, находящиеся далеко от основной части данных. Их часто легко выявить и удалить.

Контекстуальные выбросы: **Контекстуальные выбросы** — это точки данных, которые необычны в конкретном контексте, но могут не являться выбросами в другом контексте. Их часто сложнее выявить, и для определения их значимости может потребоваться дополнительная информация или знания в предметной области.

Методы обнаружения выбросов в ML:

Выявление выбросов играет решающую роль в обеспечении качества и точности моделей ML. Эффективно выявляя и удаляя или обрабатывая выбросы, мы можем предотвратить их влияние на модель, снижение ее производительности и ухудшение интерпретируемости. Ниже представлен обзор различных методов выявления выбросов:

1. Статистические методы:

Метод Z-оценки (Z-score¹) или **стандартизированного отклонения:** Этот метод часто называют методом обнаружения и удаления выбросов в нормальном распределении. Метод вычисляет стандартное отклонение точек данных и определяет выбросы как те, у которых Z-показатель превышает определенный порог (обычно 3 или -3).




Рис. 1.

¹ zscore. <https://docs.scipy.org/doc/scipy/reference/generated/scipy.stats.zscore.html>

Первое предположение перед использованием метода z-оценки заключается в том, что данные (столбец) должны иметь нормальное распределение (или колоколообразную кривую), что также означает, что больший процент значений находится в центре, а меньший процент — по обе стороны, как показано на рисунке 1 выше.

Во-вторых, любое значение, выходящее за пределы $\mu + 3(\sigma)$ и $\mu - 3(\sigma)$, называется **выбросом**.

Теперь, после обнаружения выбросов с помощью метода z-оценки, можно обрабатывать эти выбросы двумя разными способами:

→ **Обрезка (trimming)**: можно удалить данные, выходящие за пределы $\mu + 3(\sigma)$ и $\mu - 3(\sigma)$. Например: если у нас есть нормально распределенный столбец с 1000 строками, из которых 5 значений выходят за пределы $\mu + 3(\sigma)$ и $\mu - 3(\sigma)$, то можно удалить эти 5 значений, и в наших новых данных будет 995 значений.

→ **Ограничение (capping)**: можно ограничить (заменить) выбросы, обнаруженные с помощью метода z-оценки, сохраняя пороговое значение с обеих сторон. Пороговое значение должно поддерживаться верхним и нижним пределами, где верхний предел $= \mu + 3(\sigma)$, а нижний предел $= \mu - 3(\sigma)$. Таким образом, если в нашем столбце (данных) верхний предел равен 55, а нижний — 2, то любые значения, лежащие после 55 и ниже, будут заменены соответствующими числами.

Межквартильный размах (IQR): IQR определяет выбросы как точки данных, выходящие за пределы диапазона, заданного $Q1-k$ ($Q3-Q1$) и $Q3+k$ ($Q3-Q1$), где $Q1$ и $Q3$ — первый и третий квартили, а k — фактор (обычно 1,5).

2. Методы, основанные на расстоянии:

Метод k-ближайших соседей (KNN): KNN определяет выбросы как точки данных, от которых k ближайших соседей находятся на значительном расстоянии.

Локальный коэффициент выбросов (Local Outlier Factor, LOF): Этот метод вычисляет локальную плотность точек данных и идентифицирует выбросы как те, у которых плотность значительно ниже по сравнению с их соседями.

3. Методы, основанные на кластеризации:

Кластеризация пространственных данных приложений на основе плотности с учетом шума (DBSCAN): В методе DBSCAN точки данных кластеризуются на основе их плотности, а выбросы идентифицируются как точки, не принадлежащие ни одному кластеру.

Иерархическая кластеризация: Иерархическая кластеризация включает в себя построение иерархии кластеров путем итеративного слияния или разделения кластеров на основе их сходства. Выбросами можно считать кластеры, содержащие только одну точку данных, или кластеры, значительно меньшие по размеру, чем другие.

4. Другие методы:

Изоляционный лес: Изоляционный лес случайным образом изолирует точки данных путем разделения признаков и быстро и легко идентифицирует выбросы как изолированные объекты.

Одноклассовая машина опорных векторов (One-class Support Vector Machines, OCSVM): Одноклассовая SVM определяет границу вокруг нормальных данных и идентифицирует выбросы как точки, выходящие за пределы этой границы.

Методы обработки выбросов в ML

Выбросы — точки данных, значительно отклоняющиеся от большинства, — могут оказывать негативное влияние на модели ML. Для решения этой проблемы можно использовать несколько эффективных методов обработки выбросов:

1. Удаление:

Это включает в себя выявление и удаление выбросов из набора данных перед обучением модели. Распространенные методы включают:

Пороговая обработка: Выбросами считаются точки данных, превышающие определенный порог (например, Z-оценка > 3).

Методы, основанные на расстоянии: выбросы определяются на основе расстояния до ближайших соседей.

Кластеризация: Выбросами считаются точки, не принадлежащие ни к одному кластеру или принадлежащие к очень малым кластерам.

2. Трансформация:

Это включает в себя преобразование данных для уменьшения влияния выбросов. К распространенным методам относятся:

Масштабирование: Стандартизация или нормализация данных таким образом, чтобы среднее значение равнялось нулю, а стандартное отклонение — единице.

Винзоризация: замена выбросов ближайшим значением, не являющимся выбросом.

Логарифмическое преобразование: Применение логарифмического преобразования для сжатия данных и уменьшения влияния экстремальных значений.

3. Надежная оценка:

Это предполагает использование алгоритмов, менее чувствительных к выбросам. В качестве примеров можно привести следующие:

Надежная регрессия (Robust regression): алгоритмы, такие как L1-регуляризованная регрессия или регрессия Хубера, менее подвержены влиянию выбросов, чем регрессия методом наименьших квадратов (Линейная регрессия).

М-оценщики: Эти алгоритмы оценивают параметры модели на основе устойчивой целевой функции, которая минимизирует влияние выбросов.

Алгоритмы кластеризации, нечувствительные к выбросам: такие алгоритмы, как DBSCAN, менее подвержены влиянию выбросов, чем кластеризация методом K-средних.

4. Моделирование выбросов:

Это предполагает явное моделирование выбросов как отдельной группы. Это можно сделать следующим образом:

Добавление отдельной функции: Создайте новую функцию, указывающую, является ли точка данных выбросом или нет.

Использование модели смешанных распределений: обучите модель, которая предполагает, что данные получены из смеси нескольких распределений, где одно распределение представляет собой выбросы.

Важность выявления выбросов в ML:

Выявление выбросов важно в ML по нескольким причинам:

Смещенные модели: Выбросы могут смещать модель ML в сторону выбросов, что приводит к снижению производительности на остальных данных. Это может быть особенно проблематично для алгоритмов, чувствительных к выбросам, таких как линейная регрессия.

Снижение точности: выбросы могут вносить шум в данные, затрудняя для модели ML выявление истинных закономерностей. Это может привести к снижению точности и производительности.

Увеличение дисперсии: Выбросы могут увеличить дисперсию модели ML, делая ее более чувствительной к небольшим изменениям в данных. Это может затруднить обучение стабильной и надежной модели.

Сниженная интерпретируемость: выбросы могут затруднить понимание того, чему научилась модель ML на основе данных. Это может снизить доверие к прогнозам модели и помешать усилиям по улучшению ее производительности.

Заключение:

Выявление и обработка выбросов являются важнейшими аспектами построения надежных и устойчивых моделей ML. Понимание влияния выбросов, выбор подходящего метода для конкретных данных и задачи, а также использование знаний в предметной области и визуализации данных могут гарантировать, что ваши модели будут хорошо работать с ранее не встречавшимися данными и предоставлять точные и достоверные прогнозы.

ЗАДАНИЕ.

Реализуйте первичный анализ данных о фильмах, используя набор данных `Dataset1.csv`.

Для этого выполните следующее.

1). *Чтобы иметь возможность сравнивать фильмы разных лет, необходимо будет преобразовать валовую и бюджетную стоимость в реальные суммы в долларах с точки зрения покупательной способности 2016 г.* Для этого используйте индекс потребительских цен (Consumer Price Index, CPI) с поправкой на инфляцию <https://www.usinflationcalculator.com/inflation/consumer-price-index-and-annual-percent-changes-from-1913-to-2008/>

Посчитайте значения CPI за каждый год с 1912 по 2016 гг включительно. Используя **Калькулятор инфляции в США** в качестве источника и постройте DataFrame.

Пример кода представлен в файле [Задание.pdf](#) Полученную таблицу, содержащую CPI, экспортируйте в файл формата *.csv с именем Practice2_Фамилия_CPI, например, `Practice2_Ivanov_CPI.csv`

Самостоятельно изучите команду экспорта датафрейма в файл CSV: https://pandas.pydata.org/docs/reference/api/pandas.DataFrame.to_csv.html

2). *Обработать выбросы.*

3). *С помощью визуального EDA ответьте на следующие вопросы:*

1. Как распределены рейтинги фильмов (IMDb score)?
2. Существует ли зависимость между бюджетом фильма и его кассовыми сборами?
3. Какие жанры встречаются чаще всего?
4. Влияет ли количество проголосовавших пользователей на итоговый рейтинг?
5. Есть ли связь между суммарными лайками актёров в Facebook и рейтингом фильма?
6. Как изменялся средний бюджет фильмов по годам?
7. Какие страны лидируют по количеству произведённых фильмов?
8. Каково распределение длительности фильмов?
9. Различаются ли кассовые сборы в зависимости от возрастного рейтинга?
10. Кто из режиссёров снял больше всего фильмов в данной выборке?

