

Практическая работа №3.

МУЛЬТИКОЛЛИНЕАРНОСТЬ В ЗАДАЧЕ РЕГРЕССИИ МАШИННОГО ОБУЧЕНИЯ

Мультиколлинеарность — это ситуация в регрессионном анализе, при которой **две или более независимых переменных сильно коррелируют**. В этом случае становится сложно определить индивидуальное влияние каждой переменной на зависимую переменную, поскольку они изменяются синхронно.

Наличие мультиколлинеарности может привести к нестабильности оценок коэффициентов, которые могут значительно меняться при добавлении или удалении независимых переменных. Кроме того, это отвлекает внимание от важности отдельных предикторов.

Понимание и устранение. Вот почему это так важно?

1. **Достоверные оценки коэффициентов:** мультиколлинеарность может привести к неверной оценке коэффициентов регрессии. Это означает, что влияние отдельных предикторов на результат может быть представлено неверно.

2. **Интерпретируемость модели:** основная цель регрессионного анализа — понять, как различные переменные влияют на результат. При наличии мультиколлинеарности становится сложно определить индивидуальное влияние каждого предиктора. Это затрудняет понимание и снижает полезность модели как инструмента для получения аналитической информации.

3. **Обобщение:** модели, страдающие от мультиколлинеарности, могут плохо обобщать данные при работе с новыми, ранее не встречавшимися данными. Это связано с тем, что нестабильные оценки коэффициентов могут приводить к ошибочным прогнозам при применении к другим наборам данных.

4. **Повышенная сложность модели:** мультиколлинеарность может сделать модель более сложной, чем необходимо. Модель, включающая избыточные предикторы, может требовать больше данных для эффективного обучения, быть более сложной для интерпретации и подверженной **переобучению**.

Пример расчета стоимости жилья

Прогнозирование целевой переменной '**Цена дома (\$)**' на основе следующих предикторов: '**Площадь дома (кв.м)**', '**Количество спален**' и '**Возраст дома (лет)**' (рис. 1).

Площадь дома (кв. м)	Количество спален	Возраст дома (лет)	Цена дома (\$)
2000	3	5	300,000
2500	4	3	400,000
1800	3	8	280,000
2200	4	2	350,000
2400	5	4	380,000
2100	3	6	320,000
2300	4	7	360,000

Рис. 1. Фрагмент таблицы

Пример мультиколлинеарности

Типичный пример мультиколлинеарности — сильная корреляция между признаками '**Размер дома**' и '**Количество спален**'. В больших домах обычно больше спален. Из-за этой взаимосвязи сложно определить, какой из этих факторов сильнее влияет на стоимость дома.

Выявление мультиколлинеарности и работа с ней

Для измерения мультиколлинеарности чаще всего используются два метода:

- **матрица корреляций**: содержит значения корреляции каждого признака со всеми остальными признаками. Экстремальные значения указывают на высокую корреляцию;
- **коэффициент увеличения дисперсии (Variance Inflation Factor, VIF)** — это еще один метод количественной оценки корреляции, при этом значение 1 означает отсутствие коллинеарности, а >5 означает высокую коллинеарность.

Чтобы справиться с мультиколлинеарностью:

Мультиколлинеарные переменные с корреляцией выше порогового значения обычно исключаются из набора данных. Это уменьшает размерность и упрощает модель.

Существует множество других методов борьбы с мультиколлинеарностью, таких как:

- линейная комбинация признаков;
- иногда устранение мультиколлинеарности можно достигнуть путем выбора подмножества переменных, основанного на их значимости или вкладе в объяснение зависимой переменной. Это можно сделать с помощью автоматических методов отбора признаков, таких как **stepwise regression**, где переменные добавляются или удаляются из модели на основе их статистической значимости;
- **метод главных компонент (PCA)**;
- **регуляризация**: регрессия с Ridge и Lasso позволяет справиться с мультиколлинеарностью.

Устранение мультиколлинеарности

ШАГ 1. Проверьте корреляцию

Изучить линейные зависимости между независимыми переменными. Высокая корреляция между переменными указывает на возможную **мультиколлинеарность**.

```
# Import necessary functions
import pandas as pd
import numpy as np
import seaborn as sns
import matplotlib.pyplot as plt

# Sample dataset
np.random.seed(42)
house_size = np.random.randint(1800, 2600, 100)
num_bedrooms = (house_size / 500).astype(int)
house_age = np.random.randint(1, 10, 100)
house_price = 5000 + 100 * house_size + -5000 * num_bedrooms + -3000 * house_age + np.random.normal(0, 10000, 100)

data = pd.DataFrame({
    'House Size (sq.ft)': house_size,
    'Number of Bedrooms': num_bedrooms,
    'House Age (yrs)': house_age,
    'House Price ($)': house_price
})

# Calculate and visualize correlations
correlation_matrix = data.corr()
plt.figure(figsize=(10, 7))
sns.heatmap(correlation_matrix, annot=True, cmap='coolwarm')
plt.title("Correlation Matrix")
plt.show()
```

На тепловой карте корреляционной матрицы мы видим (рис. 2):




Рис. 2. Тепловая карта

1. **House Size (Размер дома)** в зависимости от **Number of Bedrooms (Количества спален)**: очень высокая корреляция (~ 0.88). Это указывает на то, что с увеличением размера дома количество спален также имеет тенденцию увеличиваться.
2. **House Size (Размер дома)** и **House Price (Цена дома)**: очень высокая корреляция (~ 0.82) предполагает, что цены на дома большего размера, как правило, выше.
3. **Number of Bedrooms (Количества спален)** и **House Age (Возраст дома)**: слабая отрицательная корреляция (-0.06), указывающая на то, что количество спален оказывает незначительное негативное влияние на возраст дома.
4. **House Age (Возраст дома)** и **House Price (Цена дома)**: отрицательная корреляция (-0.33) указывает на то, что старые дома, как правило, стоят дешевле.

ШАГ 2. Рассчитать VIF для признаков

Рассчитать **Variance Inflation Factor (VIF)** для каждого признака, чтобы оценить степень **мультиколлинеарности**.

```
# Import necessary functions
from statsmodels.stats.outliers_influence import variance_inflation_factor

# Calculate VIF
features = data.drop("House Price ($)", axis=1)
vif_data = pd.DataFrame()
vif_data["VIF"] = [variance_inflation_factor(features.values, i) for i in range(features.shape[1])]
vif_data["Feature"] = features.columns
vif_data
```

VIF	Особенность
171.553652	Площадь дома (кв. м)
157.601331	Количество спален
4.275736	Возраст дома (лет)

Рис. 3. Применение коэффициента VIF

Вот что показывают значения VIF:

- **Площадь дома (кв. м):** VIF примерно равен 171,55, что значительно выше общепринятого порога в 5–10, указывающего на высокую степень мультиколлинеарности.
- **Количество спален:** VIF примерно равен 157,60, что снова указывает на высокую степень мультиколлинеарности.
- **Возраст дома (лет):** коэффициент мультиколлинеарности составляет примерно 4,28, что говорит о том, что эта переменная не так сильно подвержена мультиколлинеарности, как две другие.

Высокие значения VIF для «Размера дома» и «Количества спален» подтверждают наше предыдущее наблюдение, сделанное на основе корреляционной матрицы: эти две переменные сильно коррелируют и могут вызывать проблемы с мультиколлинеарностью в данной регрессионной модели.

ШАГ 3. Регуляризация модели

Применить Ridge Regression — метод регуляризации, предназначенный для устранения **мультиколлинеарности**, — и визуализация значения коэффициентов для каждого признака.

```
from sklearn.linear_model import Ridge

# Split data into features and target
X = data.drop("House Price ($)", axis=1)
y = data["House Price ($)"]

# Implement Ridge Regression
ridge = Ridge(alpha=1.0)
ridge.fit(X, y)

# Visualize coefficients
coefs = pd.DataFrame({
    'Feature': X.columns,
    'Coefficient': ridge.coef_
})

plt.figure(figsize=(10, 5))
sns.barplot(data=coefs, x='Feature', y='Coefficient', palette='viridis')
plt.title('Ridge Regression Coefficients')
plt.ylabel('Coefficient Value')
plt.show()
```

На гистограмме (рис. 4) показаны значения коэффициентов из **модели гребневой регрессии**.




Рис. 4. Гистограмма

- **Площадь дома (кв. м):** коэффициент положительный, что указывает на тенденцию к росту цены дома с увеличением его площади.

- **Количество спален:** коэффициент отрицательный. Это означает, что при прочих равных увеличение количества спален приведет к снижению цены дома. Это может показаться нелогичным, но помните, что эта переменная сильно коррелирует с «площадью дома». Отрицательный коэффициент может быть связан с тем, что метод гребневой регрессии пытается сбалансировать влияние факторов «Площадь дома» и «Количество спален» из-за мультиколлинеарности.

- **Возраст дома (лет)** β : коэффициент отрицательный, что означает, что старые дома, как правило, стоят дешевле, что согласуется с нашей матрицей корреляции.

Подводя итог, можно сказать, что метод гребневой регрессии корректирует коэффициенты для устранения мультиколлинеарности в данных используемого датасета. Точная интерпретация этих коэффициентов, особенно при наличии мультиколлинеарности, может быть непростой задачей. Важно подходить к этому вопросу с осторожностью и учитывать более широкий контекст и другие потенциальные искажающие факторы.

Основные выводы

1. **Распознавание имеет решающее значение** β : выявление мультиколлинеарности — первый шаг к ее устранению.
2. **Мультиколлинеарность — это не всегда плохо:** особенно если основная цель — прогнозирование, а не интерпретация коэффициентов.
3. **На помощь приходит регуляризация:** Ridge- и Lasso-регрессия могут устранить мультиколлинеарность без удаления переменных.

Распространенные ошибки и заблуждения

1. **Игнорирование проблемы:** игнорирование мультиколлинеарности может привести к неверной интерпретации коэффициентов.
2. **Ненужное исключение переменных:** необоснованное исключение переменных может привести к потере информации.
3. **Ориентация исключительно на корреляцию:** корреляционные матрицы полезны, но отражают только линейные зависимости. VIF дает более целостное представление.

Заключение

Мультиколлинеарность может стать серьёзным препятствием при интерпретации результатов регрессионного анализа, но при наличии подходящих инструментов и понимания природы проблемы с ней можно успешно справиться. Важно своевременно выявить её, оценить последствия и выбрать адекватный метод коррекции – будь то удаление переменных, регуляризация или использование методов понижения размерности.

ЗАДАНИЕ:

1. Перейти по указанной ссылке и скачать датасет¹ для прогнозирования стабильности интеллектуальных энергосетей:

<https://archive.ics.uci.edu/dataset/471/electrical+grid+stability+simulated+data>

2. Решить задачу регрессии (целевая переменная **stab**).

2.1. Выполнить предварительную обработку данных и выполнить EDA.

2.2. Построить корреляционную матрицу для 12 признаков (коэффициент корреляции Пирсона) и визуализировать в виде тепловой карты. Описать выявленные зависимости, указав коэффициент корреляции.

2.3. Оценить мультиколлинеарность с помощью тепловой карты и расчета VIF.

2.4. Для построения прогнозных моделей рекомендуется использовать регуляризацию (Ridge, Lasso, ElasticNet).

2.5. Создать таблицу результатов (объект DataFrame), в которой укажите названия регрессоров и значения метрик качества на обучающей и тестовой выборках. Обеспечьте нужное количество знаков после запятой (см. Образец 1).

Образец 1

Перепсcop	Train Data					Test Data				
	R^2	MSE	RMSE	MAE	MAPE	R^2	MSE	RMSE	MAE	MAPE
Linear Regression	0.XX	0.XXXX	0.XXXX	0.XXXX	0.XXXX	0.XX	0.XXXX	0.XXXX	0.XXXX	0.XXXX
...										

2.6. Написать вывод о выполненной Практической работе №3.